Day2_Practice

End2End 데이터 분석 프로젝트

프로젝트 주제

"뉴욕에서 택시를 가장 가성비 있게 이용하려면 어떻게 해야 할까?"

뉴욕 여행객은 Uber•Subway•Yellow Taxi 등 다양한 교통수단을 선택 가능.

그중 Yellow Taxi 이용을 가정했을 때 "언제, 어떤 상황에서 타는 것이 가장 경제적인가"라는 질문에서 출발.

실제 운행 데이터를 분석하여 시간대거리•추가요금이 비용에 미치는 영향을 확인하고, 최종적으로 가성비 좋은 탑승을 분류하는 머신러닝 모델을 구축.

핵심 지표 정의

```
cost_per_mile = total_amount / trip_distance
```

< total_amount 사용 이유 >

기본 운임뿐 아니라 공항 수수료•혼잡 통행료 등 승객이 실제로 지불한 전액을 반영하기 위함.

운행 거리가 서로 다른 이용을 동일 기준으로 비교하려고 거리로 나눈 단가를 지표로 채택.

분석 흐름



가설 설정 및 검증

ID	가설	검증 방법
H1	비피크 시간에 이용하면 더 가성비가 좋을 것	단측 t-test
H2	추가요금이 없는 운행이 더 가성비가 좋을 것	단측 t-test
H3	이동거리가 길수록 가성비가 좋아질 것	거리 구간별 집계
H4	심야에는 오히려 가성비가 좋아질 것	그룹 비교

Step1 데이터 준비 (Data Preparation)

데이터 수집 및 로딩 성능 비교

```
[안내] 캐시된 원본 파일 재사용: output/yellow_tripdata_2026-05.parquet

=== 1) 데이터 로딩 비교: Pandas vs Polars ===
[Pandas] shape=(4090836, 20), 로딩 0.43s, 메모리 777.5MB
[Polars] shape=(4090836, 20), 로딩 0.11s, 메모리 549.7MB
[비교] 두 라이브러리 결과 shape 일치 여부: True
[안내] 실습 편의를 위해 300,000행으로 랜덤 샘플링
```

NYC Yellow Taxi Trip Records(2026-05) 4,090,836건을 Pandas•Polars 양쪽으로 로딩하여 성능 비교.

두 라이브러리의 shape가 True로 일치하여 동일 데이터를 읽었음을 확인.

Library	로딩 시간	메모리 사용량	결과 shape
Pandas	0.43초	777.5 MB	$(4090836, 20)$
Polars	0.11초	549.7 MB	$(4090836, 20)$

Polars가 로딩 속도 약 3.9 배 빠름, 메모리 29% 절감.

Polars는 문자열을 사전(dictionary) 인코딩으로 저장하고 컬럼을 지연 복사하는 구조라 메모리 효율이 높음.
(로딩 시간은 디스크 캐시 상태에 따라 변동)

실습 환경의 메모리•시간 제약을 고려하여 최종 분석은 고정 난수(random_state=42)로 300,000건 랜덤 샘플링 후 진행.
난수를 고정했으므로 재실행 시 동일 표본이 재현됨.

Step2 데이터 전처리

원본 데이터에 결측치와 현실적이지 않은 운행 기록이 포함되어 있어 분석 전 정제 수행.

(1) 결측치 확인 / (2) 중복 제거 / (3) 이상치 제거



<결측치>

- passenger_count
- RatecodeID
- store_and_fwd_flag
- congestion_surcharge
- Airport_fee

⇒ 5개 컬럼에서 각 70,180건 발생.

⇒ 다섯 컬럼의 결측 건수가 완전히 동일한 점으로 미루어 특정 제출 형식의 레코드에서 일괄 누락된 것으로 추정.

⇒ 중복 - 0건으로 제거 대상 없음.

(3) 이상치 제거 - 기준과 근거

단계	기준	제거 건수
도메인 기반 필터	운행 거리 0.1~100 mile 운임 $2.5~300 운행 시간 1~180분 승객 수 1~6명	16,319건
cost_per_mile IQR	정상범위 0.00 ~ 29.85 $/mile	12,574건

<도메인 기준 근거>

뉴욕 택시 최소요금이 약 $3.00 수준이므로 $2.5 미만은 데이터 오류로 간주.

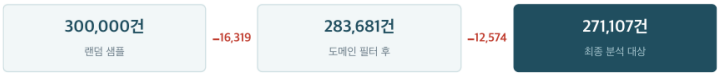
거리 0 또는 100마일 초과, 운행 시간 1분 미만-3시간 초과, 승객 수 0명 ~ 7명 이상은 비정상 기록으로 판단.

IQR 계산 근거

항목	값
Q1 (1사분위수)	8.15 $/mile
Q3 (3사분위수)	16.83 $/mile
$\mathrm{IQR} = \mathrm{Q3} - \mathrm{Q1}$	8.68
하한 = Q1 - 1.5 × IQR	-4.87 → 0 으로 보정
상한 $= \mathrm{Q3} + 1.5 \times \mathrm{IQR}$	29.85
실제 제거 대상	상한 초과 12,574건 (하한 미만 0건)

$1.5\times$ IQR 공식상 하한이 음수(-4.87)로 계산되나, 마일당 비용은 음수가 될 수 없는 값이므로 0으로 보정 → 실질적으로는 상한을 넘는 극단치, 즉 초단거리에 비정상적으로 높은 요금이 기록된 운행만 제거됨.

정제 결과



원본 표본의 90.4% 를 보존하며 분석 신뢰도를 확보.

Step 3 파생 변수 생성

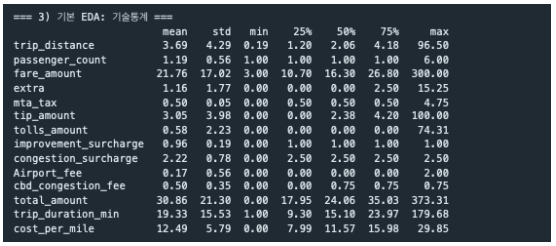
단순 운행 데이터만으로는 가성비 판단이 어려우므로 아래 파생 변수를 생성.

파생 변수	식	의미	넣은 이유
trip_duration_min	(하차 시각 - 승차 시각) 초 단위 값 / 60	운행 시간(분)	같은 거리라도 교통 정체•운행 시간에 따라 가성비가 달라 질 수 있기 때문
cost_per_mile	total_amount / trip_distance	승객이 지불한 마일당 비용	운행 거리가 서로 다른 택시 이용을 동일한 기준으로 비교 하기 위해 사용
is_peak_hour	승차 시각이 8, 9, 18, 19, 20시면 1	출퇴근 피크 출발 여부	출퇴근 시간의 정체와 수요 증가가 마일당 비용에 영향을 주는지 확인하기 위해
is_late_night	승차 시각이 22~5시면 1	심야 운행 여부	심야에는 교통량과 운행 패턴이 달라져 가성비에도 차이가 생길 수 있기 때문
has_surcharge	Airport_fee > 0 또는 congestion_surcharge > 0 또는 cbd_congestion_fee > 0	공항수수료•혼잡 통행료 발생 여부	부대비용이 실제 마일당 비용을 높이는지 확인하기 위해 사용
is_cost_effective	cost_per_mile ≤ 11.57 이면 1	마일당 비용이 중앙값 이하인 가성비 운행 여부 (label)	가성비 여부를 예측하는 ML Label로 사용하고, 데이터를 거의 50:50으로 나누기 위해

라벨을 중앙값 분할(median split)로 정한 이유 - 임의의 절대 임계값을 피하고, 두 클래스가 자동으로 균형(135,554 : 135,553)을 이뤄 분류 모 델 학습과 성능 해석에 유리하기 때문.
덕분에 무작위 추측 기준선이 50% 로 명확해짐.

Step 4 탐색적 데이터 분석 (EDA)

기본 통계 분석



```
=== 3) 기본 EDA: 기술통계 ===
                        mean    std   min    25%    50%    75%     max
trip_distance           3.69   4.29  0.19   1.20   2.06   4.18   96.50
passenger_count         1.19   0.56  1.00   1.00   1.00   1.00    6.00
fare_amount            21.76  17.02  3.00  10.70  16.30  26.80  300.00
extra                   1.16   1.77  0.00   0.00   0.00   2.50   15.25
mta_tax                 0.50   0.05  0.00   0.50   0.50   0.50    4.75
tip_amount              3.05   3.98  0.00   0.00   2.38   4.20  100.00
tolls_amount            0.58   2.23  0.00   0.00   0.00   0.00   74.31
improvement_surcharge   0.96   0.19  0.00   1.00   1.00   1.00    1.00
congestion_surcharge    2.22   0.78  0.00   2.50   2.50   2.50    2.50
Airport_fee             0.17   0.56  0.00   0.00   0.00   0.00    2.00
cbd_congestion_fee      0.50   0.35  0.00   0.00   0.75   0.75    0.75
total_amount           30.86  21.30  0.00  17.95  24.06  35.03  373.31
trip_duration_min      19.33  15.53  1.00   9.30  15.10  23.97  179.68
cost_per_mile          12.49   5.79  0.00   7.99  11.57  15.98   29.85
```

	평균	중앙값	표준편차	최솟값	최댓값
이동 거리 (mile)	3.69	2.06	4.29	0.19	96.5
운행 시간 (분)	19.33	15.1	15.53	1.0	179.68
총결제금액 ($)	30.86	24.06	21.3	0.0	373.31
마일당 비용 ($/mile)	12.49	11.57	5.79	0.0	29.85

<공통 의견>

핵심 지표 cost_per_mile의 평균 $\$12.49$, 중앙값 $\$11.57$ 로 평균이 중앙값보다 높아 분포가 오른쪽으로 치우친(우측 꼬리) 형태임을 시사.

이동 거리는 중앙값 2.06마일로 단거리 운행이 대다수를 차지.

상욱: 단거리 운행이 대다수지만, 장거리 및 이상치 영향으로 비용과 거리의 분포가 우측으로 치우쳐있음.

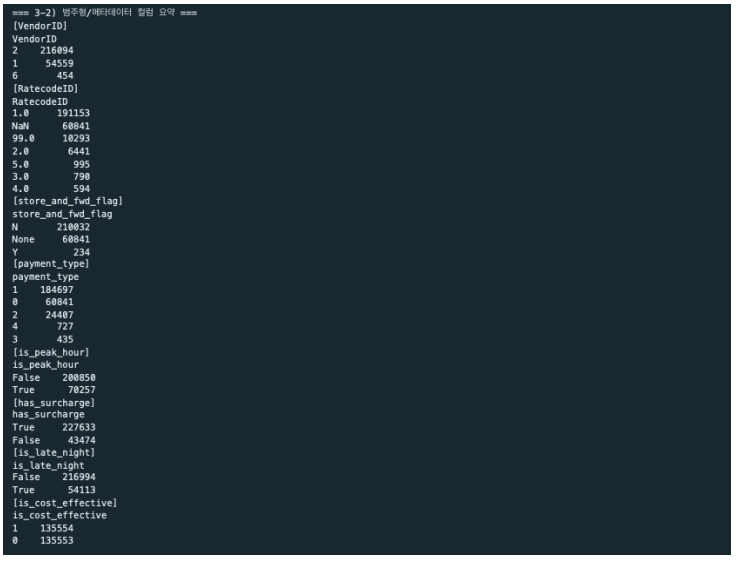
정윤: 소수의 고비용 값이 평균을 중앙값보다 높도록 만든 것으로 보임.

준형: 운임 중앙값 $16.30 대비 총결제금액 중앙값이 $24.06으로 약 48% 높아, 실제 지불액에서 부대비용·팁이 차지하는 비중이 상당함을 확인.

동주: 마일당 비용이 평균 > 중앙값($12.49 vs $11.57)으로 우측에 치우친 건 단거리 고단가 운행 때문이며, '단거리일수록 마일당 비용이 튄다'는 핵심이 기술통계에서부터 드러남을 알 수 있음.

경은: 운행 거리와 시간의 최댓값이 각각 96.5마일과 179.68분인 것을 보아, 일반적인 운행과 성격이 다른 장거리 운행도 일부 포함된 것으로 보임.

범주형 • 메타데이터 컬럼 요약

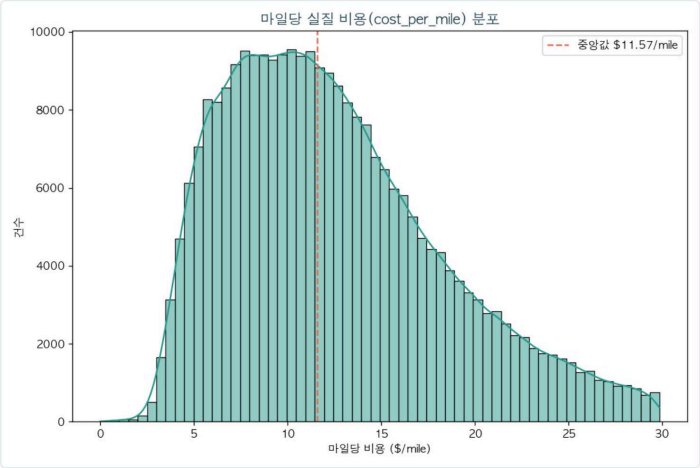


```
=== 3-2) 범주형/메타데이터 컬럼 요약 ===
[VendorID]
VendorID
2    216094
1     54559
6       454
[RatecodeID]
RatecodeID
1.0     191153
NaN      60841
99.0     10293
2.0       6441
5.0        995
3.0        790
4.0        594
[store_and_fwd_flag]
store_and_fwd_flag
N       210032
None     60841
Y          234
[payment_type]
payment_type
1    184697
0     60841
2     24407
4       727
3       435
[is_peak_hour]
is_peak_hour
False    200850
True      70257
[has_surcharge]
has_surcharge
True     227633
False     43474
[is_late_night]
is_late_night
False     216994
True       54113
[is_cost_effective]
is_cost_effective
1    135554
0    135553
```

is_cost_effective가 135,554 대 135,553으로 정확히 반반 분할 - 중앙값 기준 라벨링의 의도대로 균형 확보.

has_surcharge는 True 227,633 건(84%) 대 False 43,474건(16%)으로, 추가요금 없는 운행은 전체의 16%에 불과함을 확인.

마일당 비용 분포



<공통 의견>

마일당 비용의 중앙값은 $11.57이며, 이 값을 기준으로 이하인 운행을 '가성비 좋은 운행'으로 정의.

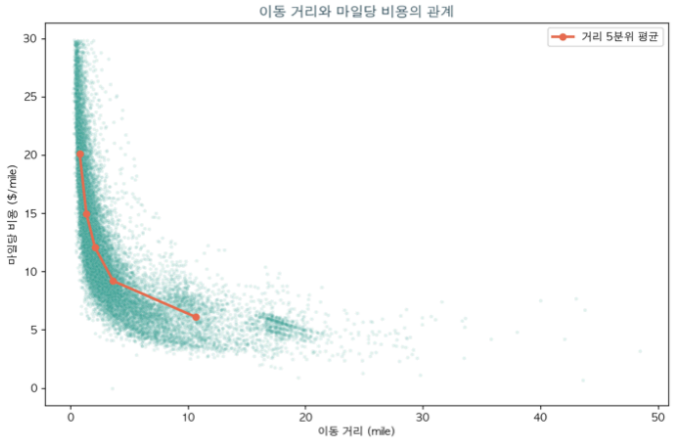
분포가 오른쪽으로 길게 이어져 일부 운행에서상대적으로 높은 마일당 비용이 관찰됨.

상욱: 중앙값 이하의 '가성비 구간'이 대다수를 차지하나, 우측 고비용 이상치 영역이 30달러선까지 길게 늘어진 구조임

정윤: 다만 중앙값으로 이분화하다 보니 정도 차이를 세분화하여 구분하지 못하는 한계가 있어 보임.

경은: 마일당 비용이 중앙값을 중심으로 넓게 분포한 것을 보아, 같은 가성비 집단에 포함된 운행 사이에도 비용 차이가 존재하는 것으로 보임.

이동 거리와 마일당 비용의 관계



<공통 의견>

거리가 짧을수록 마일당 비용이 급격히 상승하는 반비례(쌍곡선) 형태.

주황색 선은 거리 5 분위 구간별 실제 평균으로, 1 마일 미만 구간에서 $20을 넘다가 10 마일 구간에서 $6 까지 하락.

기본요금이 거리에 희석되는 구조를 시각적으로 확인.

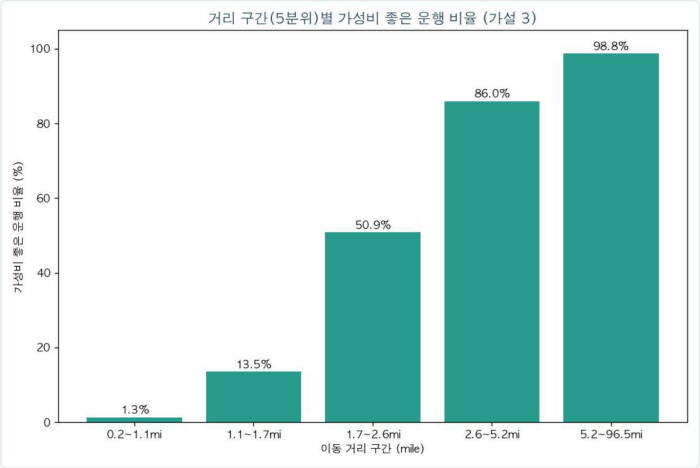
상욱: 약 3~4마일 부근을 기점으로 마일당 비용의 급격한 하락세가 꺾이며 안정화되므로, 해당 거리가 가성비 전환의 주요 임계점으로 판단.

정윤: 5분위 평균 기준 1마일 미만 구간($20대)이 10마일 구간($6대)보다 약 3배 이상 높음.

준형: 16~20마일 부근에 다른 구간과 구분되는 좁은 띠 형태의 군집이 관찰되며, 이는 거리와 무관하게 운임이 고정되는 정액요금 운행으로 확인됨.

경은: 단거리 구간에서 비용의 분산이 크게 나타나는 것을 보아, 단거리일수록 추가요금 등의 다른 요인에 따라 비용 차이가 커지는 것으로 보임.

거리 구간별 가성비 비율



<공통 의견>

이동거리가 증가할수록 가성비 좋은 운행 비율이 크게 증가.

가장 짧은 구간은 1.3%에 불과하나 가장 긴 구간에서는 98.8%로 나타남.

단거리 운행에서 기본요금과 고정 부대비용이 마일당 비용을 끌어올리기 때문으로 해석.

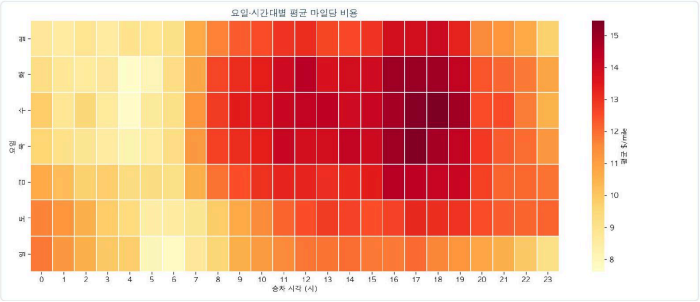
상욱: 기본요금 영향으로 단거리 승객의 마일당 비용 부담이 훨씬 크며, 일정 거리(2.6mi 이상)를 넘어서야 80% 이상의 운행이 가성비 구간에 진입

정윤: 가성비 비율이 1.3%→98.8%로 극단적으로 갈리는 것도 결국 위 반비례 관계의 연장선으로 해석됨.

준형: 5분위는 건수 기준 분할이므로 각 구간 건수는 약 54,000건으로 균등하나 거리 폭은 0.59~91.3마일로 상이하여, x축 막대 간격을 거리에 비례하는 것으로 읽지 않도록 유의.

동주: 가성비 비율이 50%를 넘어서는 지점이 거리 2마일 부근인데, 이는 표본의 거리 중앙값(2.06마일)과 거의 일치함. '절반이 가성비'라는 라벨 정의가 사실상 '중앙값 거리 이상이면 가성비'로 볼 수 있어 흥미로웠음.

요일 × 시간대별 평균 마일당 비용



<공통 의견>

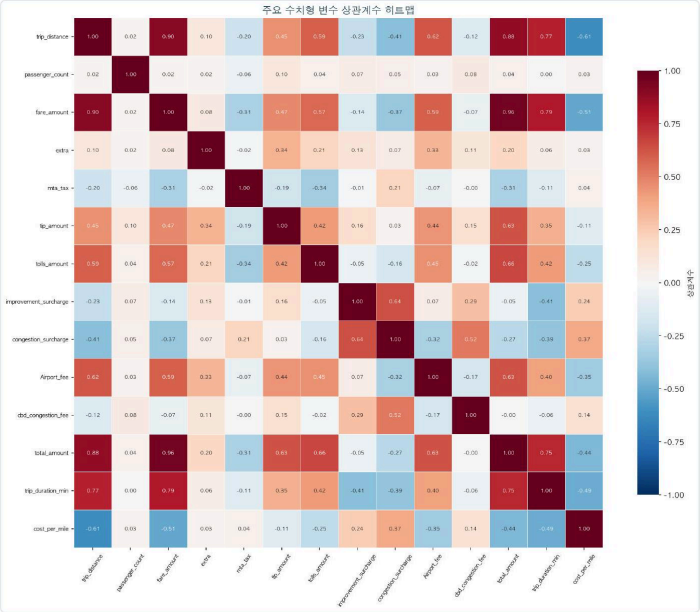
평일 낮~저녁 시간대에 비용이 집중적으로 높고, 새벽 시간대(3~6시)는 요일과 무관하게 전반적으로 낮은 패턴이 관찰됨.

상욱: 주중(월~금) 중에서도 수·목·금 오후 15~18시 사이에 가장 짙은 색(마일당 $15 이상)이 나타나, 주 후반 퇴근길 정체가 마일당 비용 상승의 핵심 요인으로 작용할 것으로 판단.

정윤: 새벽 3~6시대가 요일과 무관하게 낮게 나타난 패턴은, 뒤에 나오는 가설 4(평일 심야 64.7% vs 평일 낮 43.2%)의 방향과 일치함. 심야 정체 감소 효과와 같은 원인에서 비롯됐을 가능성이 있어 보임.

경은: 평일에는 시간대에 따라 마일당 비용의 색상 차이가 크게 나타나는 반면 주말에는 상대적으로 변화가 완만한 것을 보아, 평일 택시 비용이 출퇴근 시간과 교통의 혼잡의 영향을으로 더 많이 받는 것으로 예상됨.

상관관계 분석



- cost_per_mile ↔ trip_distance: -0.61 → trip_distance이(가) 클수록 마일당 비용이 낮아지는(음의 상관) 경향
- cost_per_mile ↔ fare_amount: -0.51 → fare_amount이(가) 클수록 마일당 비용이 낮아지는(음의 상관) 경향
- cost_per_mile ↔ trip_duration_min: -0.49 → trip_duration_min이(가) 클수록 마일당 비용이 낮아지는(음의 상관) 경향

<공통 의견>

대표 결과로 trip_distance ↔ cost_per_mile 상관계수 -0.61 - 이동 거리가 길어질수록 마일당 비용은 감소하는 뚜렷한 음의 상관.

운행 시간(-0.49), 운임(-0.51)도 같은 방향.

반대로 congestion_surcharge(+0.37)는 양의 상관으로, 혼잡료가 붙는 운행일수록 단가가 높아지는 경향.

상욱: 승객 수의 경우 주요 요금 지표 및 마일당 비용과의 상관계수가 0에 가까워, 승객 수는 운행 단가나 전체 비용에 거의 영향이 없다고 하지만 1인당 비용으로 가게 된다면 상관관계가 높을 것으로 판단

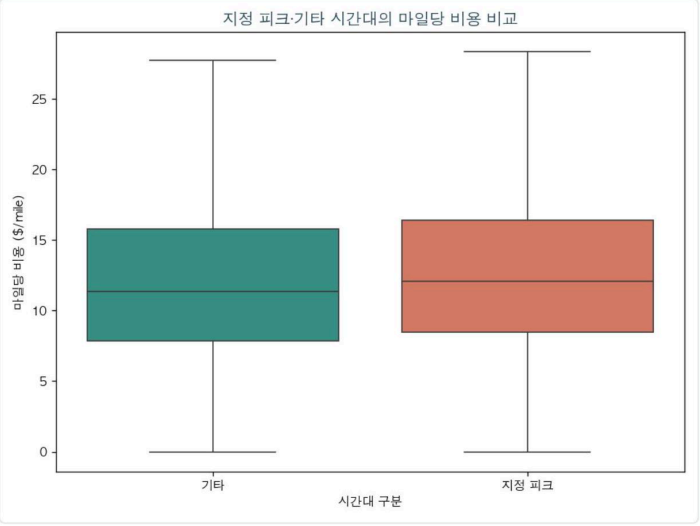
정윤: 거리·운임·운행시간이 비슷한 방향(음의 상관)으로 나온 건, 세 변수가 서로 얽혀 있어 개별 효과를 온전히 분리해서 보기는 어려움

동주: 거리와 마일당 비용의 관계는 직선이 아니라 휘어진 곡선이라, 지금의 상관계수 -0.61은 실제 관계보다 다소 약하게 나온 값일 수 있음. 곡선 관계까지 잡아주는 방식으로 보면 더 뚜렷하게 나올 것으로 생각.

Step 5 가설 검증

가설 1 비피크 시간에 택시를 이용하면 더 가성비가 좋을 것이다.

```
=== 6-1) t-test (H1): 지정 피크 vs 기타 시간대 마일당 비용 ===
지정 피크 평균: $12.929/mile (n=70,257) / 기타 시간대 평균: $12.339/mile (n=200,850)
t-statistic: 23.2675, p-value(one-sided): 8.603e-120
해석 (α=0.05): 귀무가설 기각 (지정 피크 시간대가 유의미하게 높음)
```



<공통 의견>

지정 피크(8・9•18•19•20시) 평균 $12.93 vs 기타 시간대 $12.34로 피크 시간대가 마일당 $0.59(4.8%) 높게 관찰.

p-value $8.603e-120 < 0.05$ 로 귀무가설 기각 → 비피크 시간 이용이 유리하다는 가설 채택.

다만 박스플롯상 두 집단의 사분위 범위가 상당 부분 겹쳐, 통계적 유의성 대비 실질 차이 폭은 크지 않음.

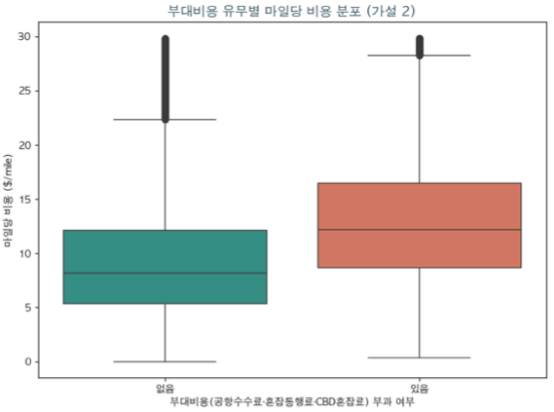
상욱: 두 집단 간 마일당 비용 차이가 통계적 유의성을 보이나, 박스플롯 상 중앙값 및 사분위 범위의 겹침이 크므로 실제 체감되는 가성비 차이는 크지 않을 수 있다는 생각.

두범: 피크 시간대의 마일당 비용이 더 높게 나타난 것은 교통 혼잡으로 같은 거리를 이동하는 데 더 많은 시간과 비용이 발생하기 때문으로 보입니다. 다만 표본이 매우 크므로 통계적 유의성뿐 아니라 실제 비용 차이의 크기도 함께
고려할 필요가 있습니다.

동주: 지금 피크가 요일 구분 없이 시각만으로 잡혀 있어서 주말 아침·저녁도 피크에 들어가는데, 평일만 따로 봐도 같은 결과인지 확인해보면 러시아워 효과가 더 선명하게 드러날 것 같음.

가설 2 추가요금이 없는 운행이 더 가성비가 좋을 것이다.

```
=== 6-2) t-test (H2): 부대비용 유무별 마일당 비용 ===
부대비용 있음 평균: $13.062/mile (n=227,633) / 부대비용 없음 평균: $9.507/mile (n=43,474)
t-statistic: 123.8463, p-value(one-sided): 0
해석 (α=0.05): 귀무가설 기각 (부대비용 있는 운행이 유의미하게 높음)
```



<공통 의견>

추가요금 있음 $13.06 vs 없음 $9.51로 약 37%의 비용 차이 발생.

p-value ≈ 0 으로 귀무가설 기각 → 가설 채택.

박스플롯에서도 두 집단의 분포가 뚜렷이 분리됨.

정윤: 차이 폭(37%)은 뚜렷하지만, surcharge 유무가 승객의 선택이 아니라 경로(공항·CBD)에 따라 정해지는 항목이라는 점에서 필수적으로 해당 경로로 가야하는 경우 또는 해당 경로를 가지 않으면 더 장거리를 가야하는 경우 등 다양한 상황에 대해서는 무조건 유리하다고는 설명하지 못함.

두범: 추가요금 유무에 따른 차이가 약 37%로 크게 나타난 만큼, 시간대보다 비용에 미치는 영향이 더 직접적인 변수로 보입니다. 다만 추가요금은 공항이나 CBD 같은 목적지에 따라 불가피할 수 있으므로, 단순히 추가요금이 없는 운행을
선택하라는 의미보다는 가능한 경우 해당 구간을 피하는 전략으로 해석해야 합니다.

<해석 시 주의사항>

추가요금 없는 운행은 전체의 16%에 불과.

따라서 이 결론은 '아무 택시나 추가요금 없는 것을 고르라'는 의미가 아니라, 공항•맨해튼 도심(CBD)을 경유하는 경로 자체가 비용을 크게 올리므로 가능하면 해당 경로를 피하는 것이 유리하다는 의미.

가설 3 이동거리가 길수록 가성비가 좋아질 것이다.

```
=== 6-3) 가설 3 진단: 거리 구간별 가성비 비율 ===
                  평균거리  평균마일당비용  가성비비율     건수
distance_bucket
(0.189, 1.07]     0.785   20.099  0.013  54591
(1.07, 1.66]      1.354   14.950  0.135  53869
(1.66, 2.6]       2.086   12.055  0.509  54624
(2.6, 5.2]        3.628    9.186  0.860  54040
(5.2, 96.5]      10.657    6.096  0.988  53983
```

거리 구간 (mile)	평균 거리	평균 마일당 비용	가성비 비율	건수
(0.189, 1.07]	0.785	$20.099	1.3%	54,591
(1.07, 1.66]	1.354	$14.950	13.5%	53,869
(1.66, 2.6]	2.086	$12.055	50.9%	54,624
(2.6, 5.2]	3.628	$9.186	86.0%	54,040
(5.2, 96.5]	10.657	$6.096	98.8%	53,983

<공통 의견>

1 마일 이하 초단거리는 가성비 좋은 비율이 1.3% 에 불과한 반면, 5.2 마일 이상 장거리 구간(평균 10.7 마일)은 $\mathbf{98.8\%}$ 가 가성비 좋은 운행으로 분류 → 가설 채택.

기본요금이 긴 거리에 희석되기 때문.

상욱: 단거리 운행 시 승객의 체감 단위 비용 부담이 매우 높으므로, 택시 서비스 만족도 및 가성비 체감은 2.6마일 이상의 중장거리 운행에서 극대화될 것으로 판단.

두범: 장거리일수록 기본요금과 고정 부대비용이 전체 거리에 분산되어 마일당 비용이 낮아지는 것으로 보입니다.
이는 장거리 택시의 총비용이 저렴하다는 의미라기보다, 동일한 1마일을 이동할 때 상대적으로 효율적이라는
의미로 해석해야 합니다.

준형: 가성비 비율의 구간별 증가폭이 +12.2%p → +37.4%p → +35.1%p → +12.8%p로 중간 두 구간에 집중되는 S자 형태를 보여, 거리 증가에 따른 가성비 전환이 1.7~5.2마일 사이에서 대부분 진행됨.

경은: 거리 구간별 범위가 동일하지 않은 것을 보아, 장거리일수록 가성비가 일정한 비율로 증가한다고 해석하기보다 연속형 분석을 추가할 필요가 있음.

<해석의 한계>

'마일당' 비용이 낮아지는 것일 뿐 총 지출은 장거리가 더 큼.

또한 본 데이터는 100 마일 초과 운행을 제외했으므로 '무조건 장거리일수록 가성비가 좋다'로 일반화 불가.

가설 4 심야에는 오히려 가성비가 좋아질 것이다.

```
=== 6-4) 가설 4 진단: 주말/심야 조합별 가성비 비율 ===
                                가성비비율      건수
is_weekend is_late_night
False      False          0.432  153165
           True           0.647   30391
True       False          0.546   63829
           True           0.629   23722
```

False	False	0.432	153165
	True	0.647	30391
True	False	0.546	63829
	True	0.629	23722

집단	가성비 비율	건수
평일 × 낮	43.2%	153,165
평일 × 심야	64.7%	30,391
주말 × 낮	54.6%	63,829
주말 × 심야	62.9%	23,722

<공통 의견>

평일 심야 64.7% vs 평일 낮 43.2% 로 심야 시간대의 가성비 비율이 뚜렷하게 높음 → 가설 채택.

뉴욕은 심야 추가요금이 존재하지만, 교통 혼잡감소 효과가 더 크게 나타난 것으로 해석.

상욱: 뉴욕 택시는 심야 추가요금(Night Surcharge)이 $1.00로 고정액인 데다, 피크 시간대 수수료($2.50)보다도 작아 할증 부담이 매우 적기 때문에 한국과 달리 심야 할증에 따른 비용 상승보다 '할증 시간대의 원활한 도로 흐름으로 인한 주행시간 단축' 효과가 훨씬 크게 작용함.

두범: 심야 추가요금이 있음에도 가성비 비율이 높게 나타난 것은 고정 할증의 영향보다 교통량 감소에 따른 이동 효율 개선이 더 크게 작용했기 때문으로 보입니다.
다만 심야 이동은 비용 외에도 안전성과 대중교통 이용 가능 여부를 함께 고려해야 합니다.

경은: 평일과 주말의 심야 가성비 비율이 각각 64.7%와 62.9%로 비슷한 것을 보아, 심야에는 요일의 영향이 크지 않은 것으로 보임.

동주: 심야 효과가 평일엔 +21.5%p인데 주말엔 +8.3%p로 차이가 나서, '심야가 좋다'와 함께 '평일 낮(러시아워)이 유독 나쁘다'는 관점도 같이 보면 해석이 더 풍부해질 것 같음.

시간대별 평균 마일당 비용 (Plotly 인터랙티브)



<공통 의견>

새벽 5시가 $8.61로 최저, 17시가 $14.09로 최고를 기록.

정윤: 새벽과 오후 러시아워의 차이(약 $5.5)가 데이터에서 가장 뚜렷한 폭이라, 승객 입장에서는 다른 조건보다 '탑승 시점 조절'이 가장 실천하기 쉬운 절약 방법으로 보임.

두범: 새벽 5시와 17시의 마일당 비용 차이가 약 $5.48로 나타나, 승객 입장에서는 탑승 시간대를 조정하는 것이 가장 실천하기 쉬운 절약 방법으로 보입니다. 다만 시간대별 운행 거리와 출발 지역의 구성이 다를 수 있으므로,
후속 분석에서는 이를 통제한 비교도 필요합니다.

경은: 시간대별 평균값만으로는 5시의 낮은 비용이 안정적인 결과인지 판단할 수 없어, 추가적으로 시간별 표본 수와 신뢰구간을 함께 확인할 필요가 있음.

<해석 시 주의사항 - 가설 1~4 공통>

모두 관찰 데이터의 집단 간 비교 결과이며 인과관계를 증명한 것이 아님.

표본이 271,107건으로 매우 크므로 작은 차이도 통계적으로 유의하게 나타날 수 있다는 점을 감안하여 해석 필요.

Step 6 머신러닝

EDA와 통계분석에서 확인한 특징을 활용하여 Random Forest 분류 모델 구축. sklearn Pipeline으로 '전처리 → 인코딩 → 모델 학습 → 평가'를 하나의 과정으로 자동화.

```
=== 7) ML Pipeline: 가성비 좋은 팁승 여부 분류 ===
[안내] 상위 20개 pickup 구역이 전체 트립의 56.5%를 커버 (전체 구역 수: 248개, 나머지는 'OTHER'로 묶임)
정확도(Accuracy): 0.8842
F1-score: 0.8850
              precision    recall  f1-score   support

      가성비 나쁨       0.89      0.88      0.88     27111
      가성비 좋음       0.88      0.89      0.88     27111

    accuracy                           0.88     54222
   macro avg       0.88      0.88      0.88     54222
weighted avg       0.88      0.88      0.88     54222

[Feature Importance 상위 10] (가성비 예측에 많이 기여한 피처 순)
trip_distance          0.6106
trip_duration_min      0.1764
ratecode_label_표준요금    0.0430
pickup_zone_132        0.0253
ratecode_label_기타      0.0230
pickup_zone_138        0.0224
pickup_hour            0.0203
has_surcharge_False    0.0155
has_surcharge_True     0.0110
is_late_night_True     0.0095
모델 저장 완료: output/cost_effective_model.joblib
```

Accuracy 88.4% / F1-score 88.5% 달성.

클래스별 precision•recall이 모두 0.87~0.89로 균형되어 한쪽 클래스에 치우치지 않은 분류 성능을 확인.

성능 결과

Random Forest 분류모델 성능 결과

성능 지표	결과	의미
Accuracy	0.8842	전체 예측 중 올바르게 분류한 비율
F1-score	0.8850	정밀도와 재현율의 조화평균
학습 데이터	216,885건	모델 학습에 사용한 데이터
테스트 데이터	54,222건	성능 평가에 사용한 데이터

학습 216,885건 / 테스트 54,222건으로 8:2 분할, stratify 적용으로 클래스 비율 유지.

trip_distance(0.61)와 trip_duration_min(0.18)이 전체 중요도의 79% 를 차지 ⇒ EDA에서 확인한 '거리가 마일당 비용을 결정한다'는 관찰과 일치하는 결과.

<모델 성격>

실제 운행거리와 운행시간을 입력으로 사용하므로 운행 완료 후 기록 기반 분류에 해당하며, 탑승 전 시점의 예측 성능을 뜻하지않음.

탑승 전 추천 서비스로 확장하려면 출발 시각•출발 지역 등 사전 정보만으로 재학습이 필요.

Step 7 자동화

```
=== 8) report.md 자동 생성 ===
저장 완료: output/report.md

모든 단계 완료. output/ 폴더를 확인하세요.
```

```
$ ls -l output/
    30,264  box_surcharge_seaborn.png
 6,015,362  cost_effective_model.joblib
    57,002  dist_seaborn.png
   246,111  eda_correlation_heatmap.png
    68,675  eda_descriptive_stats_table.png
   153,875  eda_distance_vs_cost.png
    23,881  eda_peak_boxplot.png
    35,128  eda_weekday_hour_heatmap.png
 4,860,490  group_plotly.html
    38,799  h3_distance_bucket.png
    71,572  ml_performance_table.png
    17,029  report.md
```

자동 생성 산출물 요약

파일	내용
report.md	전체 분석 결과와 해석이 담긴 마크다운 보고서
cost_effective_model.joblib	전처리 + Random Forest가 결합된 학습 완료 모델
group_plotly.html	시간대별 평균 비용 인터랙티브 차트
*.png (8종)	Seaborn 및 정적 차트 8종 (분포•산점도•박스플롯•히트맵 등 EDA 시각화)

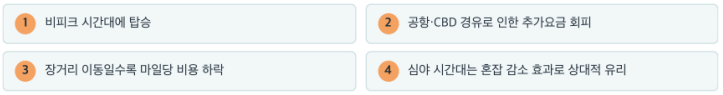
⇒ 모든 결과물이 output/ 폴더에 저장되도록 구성하여 재실행만으로 전체 산출물이 동일하게 재생성됨.

Step 8 최종 결론

가설 검증 종합

ID	결과	판정
H1	지정 피크가 기타 시간대보다 마일당 평균 $0.59 높음 (p=8.6e120) 120)	(체택) 비피크 이용이 유리
H2	부대비용 있는 운행이 마일당 평균 $3.56 높음 ($p \approx 0$)	(체택) 추가요금 회피가 유리
H3	최단거리 구간 1.3% vs 최장거리 구간 98.8%	(체택) 장거리가 유리 체택 장거리가 유리
H4	평일×심야 64.7%로 최고, 평일×낮 43.2%로 최저	(채택) 심야가 유리 체택 심야가 유리
ML	Random Forest - Accuracy 88.4% / F1 88.5%	

가성비 좋은 택시 이용 조건



⇒ Random Forest 기반 모델이 약 88.5% 의 정확도로 가성비 좋은 택시 이용 여부를 분류

→ 향후 “지금 택시를 타면 가성비가 좋은가?”를 실시간으로 추천하는 의사결정 지원 서비스로 확장할 가능성 확인.

분석의 한계

항목	내용
인과관계	관찰 데이터의 집단 간 비교 결과이며 인과관계를 증명한 것이 아님
라벨 기준	가성비 여부는 해당 표본의 cost_per_mile 중앙값($11.57)에 의존
모델 시점	실제 거리•운행시간을 사용하는 운행 완료 후 분류 모델
일반화	100마일 초과 등 도메인 범위 밖 기록을 제외하여 전체 운행으로 일반화 불가

종합 개인 의견

상욱: 데이터 분석 및 머신러닝을 통해 가성비 택시 이용 조건을 제시했지만, '가성비'라는 타깃 변수에 주관적 기준(중앙값 $11.57)을 적용했음을 고려하여 도메인 특성에 맞춘 기준 고도화가 필요할 것으로 판단됨.

정윤: 한계점에서 언급되는 항목들이 해석에 미치는 영향이 크기에, 핵심 결론은 경향성 정도로 받아들일 수 있음.

두범: 분석 결과를 종합하면 혼잡 시간과 추가요금을 피하고, 기본요금의 영향이 줄어드는 일정 거리 이상의 이동에 택시를 선택적으로 활용하는 것이 현실적인 가성비 전략이라고 생각합니다. 향후 출발 시간과 지역처럼 탑승 전에 알 수 있는 정보만으로 모델을 재학습한다면 실제 여행자의 교통수단 선택을 돕는 서비스로 확장할 수 있을 것 같습니다.

준형: 30만 표본을 409만 전체와 대조한 결과 중앙값·집단 평균·구간 비율이 모두 ±0.25% 이내로 일치하여, 한계 항목 중 표본 크기에 기인한 편향은 크지 않은 것으로 확인.

동주: 이번 모델이 실제 거리와 시간을 아는 완료 후 기준이라 88%가 높게 나온 건데, 뒤집으면 앞으로 만들 탑승 전 추천 모델의 성능 상한선이자 비교 기준으로 삼을 수 있음. 출발 시각, 지역만으로 재학습한 모델이 이 88%에 얼마나 근접하느냐가 곧 “지금 타면 가성비가 좋을까?” 실시간 추천 서비스의 실현 가능성을 가늠하는 척도가 될 것이라 생각.

경은: 본 분석은 2026년 5월 한 달의 데이터만 사용한 것을 보아 계절, 공휴일, 관광, 성수기, 기상 상황에 따른 교통량과 요금 변화를 충분히 반영하지 못한 한계가 있음. 따라서 여러 월과 계절의 데이터를 추가하여 현재의 가성비 조건이 다른 시기에도 동일하게 나타나는지 검증할 필요가 있음.